

苏格拉底式 AI 教学系统

把学生的真实状态沉淀下来，把教师的经验积累起来，
把大模型放在它该在的位置上。

院长工作室实验班 · 已完成可运行系统与本地演示



一、我们到底要解决什么问题

不谈技术清单，先谈教学闭环断在哪里

任何教学活动都是一个闭环，而它必然断在三处

知道学生现在会什么 → 决定接下来教什么 → 学生做 → 再看他会了什么

断裂	表现	后果
看不见	作业批完是三天后，考试出分是一个月后	等看见问题，课程已经推过去了
动不了	知道三分之一的人卡住，一个人面对六十人	只能按统一进度继续讲
接不上	项目做得好不好，与知识点掌握判断是两套系统	学生在项目里暴露的问题，不会修正对他的判断

- 本系统的全部使命，就是接上这三处断裂。
 - 凡不服务于此的功能，无论技术上多先进，都排在后面。

先说清楚：系统不做什么

明确不做什么，与明确做什么同样重要。以下三条是硬约束

- **不替代教师的判断。**一切输出都是建议，可采纳、可修改、可否决。
 - 否决记录用于改进系统，**不用于评价教师**。系统不生成、不留存任何针对教师的评价性数据。
- **不追求全自动。**先做诊断，后做批改。
 - 教师批完一百份作业，真正有用的信息往往只有一句话——某道题半数人做错，原因是混淆了两个概念。
 - 系统若能直接给出这句话，价值远高于替他打分。
- **不掩饰不确定。**数据不足时明说数据不足，不做精确性伪装。
 - 开学前几周判断必然不准；与其猜一个数字，不如坦白。教师对系统的信任一旦失去，很难重建。



二、唯一真正重要的技术判断

它决定这套系统能活十年，还是一年

大模型是嘴，不是脑

学生状态必须由独立的、结构化的、持久的模型维护，不交给大模型推断。

- 系统中存在一个独立的**学生状态对象**：每个学生在每个知识点上的掌握程度、在每个能力维度上的水平，以及这些状态的历史变化。
- 这个状态由**确定性算法**维护。大模型只做一件事：拿到状态之后，把该说的话说好。

这不是一句口号——本次汇报的第 4 个演示会当场把大模型接上去，让各位看结论变没变。

把状态交给大模型推断，会同时失去三样东西

混在一起 → 失去

- **可信**：换个对话上下文，判断就变了
- **可查**：说不出依据，教师无从核对
- **可积累**：换一届学生、换一个模型，系统就重新开始

分开之后 → 得到

- 大模型是**可替换件**，明年换更强的即可
- 图谱与状态是**沉淀资产**，只会越用越厚
- 两者更新节奏**完全解耦**

- 市面上多数教学产品把两者混在一起，本质上是把系统的命运绑在某一代模型上。
 - 这是它们做不长的根本原因，也是本方案与之最重要的区别。

由此，系统自然分为三层

层间只有一条规矩：生成层可以读状态，不能改状态

层	回答的问题	本质	属性
L3 生成层	接下来该说什么？	追问、讲解、任务、报告，由大模型承担	可替换
L2 状态层	这个学生现在会什么？	每人在坐标系上的位置与移动轨迹，由算法维护	可积累 · 核心资产
L1 图谱层	这门课由什么构成？	知识点及其依赖关系，是全系统的坐标系	可积累

- 所有状态变化必须由算法依据真实行为产生。**这条规矩若破了，前面所有论证都不成立。**
 - 在本系统里它不是靠自觉：数据库触发器 + 代码静态检查双重把关，违反即报错。

五个模块不是并列的工具，是一条链

诊断 → 引导 → 任务 → 审查 → 画像 → (回到诊断)

环节	模块	在链条中的作用
知道在哪	① 个性化学习诊断	定位学生此刻的位置，尤其是回溯出真正的病根
推一把	② 苏格拉底式引导	从他已会的最近一点切入追问，让他自己走过去
做起来	③ 项目任务管理	把知识放进真实任务，任务难度略高于当前水平
做得对吗	④ 代码与文档审查	从产出反查理解，把工程问题翻译回知识点
长期怎样	⑤ 学习成效画像	把单次循环拉长为成长轨迹，供导师与分流决策

④ 审查是最容易被低估的一环——它是把实践信号翻回知识判断的唯一通道。少了它，项目与课程仍是两张皮。



三、现场演示

四段演示，对应三处断裂 + 一个架构主张

演示一 · 接上「看不见」：班级诊断

教师端 → 班级诊断

- **全班知识点掌握热力图**：一眼看到红色区域在哪，可下钻到任意知识点。
- **Top 3 待攻克点**——排序不是按错误率，而是 **低掌握度 × 挡路度**。
 - 一个所有人都错、但不挡任何路的边缘知识点，不该占用下节课的时间。
- **每一条都带根因**：系统会说 " 真正卡住的是链式法则，不是反向传播 "。
- **需个别介入的学生名单**，证据不足的会标注 " 数据不足，仅供参考 "。
- **追问降级热点**：系统被迫给出提示的地方，就是该重讲的地方。
- 每一条建议旁边都有 " 否决 " 按钮。

这就是接上第一处断裂：课后当天看到全班卡在哪里，而且看到的是病根，不是症状。

根因回溯：纯大模型方案做不可靠的那一步

反向传播出错 → 沿依赖边回溯 → 真正的病根在链式法则

- 算法：对每个掌握度低于阈值的知识点，沿前置依赖边反向广度搜索；只沿 " 同样未掌握 " 的链条继续；返回最深的那个节点。
- 大模型可以说 " 可能是链式法则没学好 "，但它说不出——
 - " 这个班里有多少人的反向传播错误可以归到同一个前置点上 "，也说不出这个结论的依据是什么。
- 这一步依赖 L1 图谱的**显式依赖结构**：当前试点课程 183 个知识点、224 条依赖边，导入时强制环检测。

演示二 · 接上「动不了」：拉取式学习

学生端 → 拉取式任务 → 选一个项目任务 → 算缺口

传统做法（已废弃）

- 按知识点依赖顺序排课
- 全班统一进度往下推
- 先学半年螺丝刀，再拆引擎
- 图谱 = 教学顺序表

本系统

- 学生接到项目任务
- $\text{缺口} = \text{任务所需} - \text{已掌握}$
- 只推此刻最挡路的 1-2 个
- 图谱 = 按需检索索引

- 拓扑序仍然保留，但只用于计算缺口内部的先后，不用于安排全员进度。

缺口计算实录（确定性输出，不经大模型）

命令行：make gap STUDENT=1 TASK=T-AGV-3

缺口知识点	掌握度	挡路度	缺口内前置卡点
反向传播算法	0.214	14.0	—
卷积操作与局部感受野	0.000	2.5	—
池化与平移不变性	0.000	2.0	1 个

- 本次只推前两个。排序规则：**能立刻学的优先** → 挡路度高的优先 → 拓扑序。
 - 推一个学生此刻还学不动的知识点，等于什么也没推。
- 连带的产品要求：**去掉了课程进度百分比**。过程完全个体化之后，这个概念本身就不成立了。
 - 出口仍是统一的 30/70 考核——过程个体化，出口有门槛。

演示三 · 引导追问：不给答案，但也不放任挫败

学生端 → 引导追问 → 连点三次「我卡住了」

- 追问策略由 L2 状态确定三件事，**不交给大模型自由发挥**：
 - 起点——从学生已掌握的最近前置点切入；深度——掌握度越低拆得越细；类型——概念澄清 / 反例质疑 / 类比迁移 / 条件变更。
- 所有追问必须基于课程知识库检索结果生成，禁止脱离教材自由发挥。
- **降级机制**：关键提示 → 解题框架 → 完整解析并标记教师介入。
 - 每一次降级都写进事件流（当前演示数据里有 24 次），回到教师端就是刚才看到的降级热点。

证据：不加限制的 AI 辅助会使学生独立考试成绩下降约 17%，引导式提示则显著更优。所以降级是为了防止挫败感摧毁动机，不是为了让学生轻松。

接上「接不上」：审查是唯一的翻译通道

第一级静态分析（确定性）→ 第二级大模型评审 → 关联知识点回写 L2

代码里的问题	能否可靠映射到知识点	处理
划分数据集之前就 fit 了预处理器	能 → 数据泄漏的识别与防范	教师采纳后回写
在测试集上调阈值或选模型	能 → 验证集调参的乐观偏差	教师采纳后回写
不平衡数据只报准确率	能 → 准确率的局限	教师采纳后回写
裸 except / 函数过长 / 圈复杂度高	不能——说明工程素养，不说明知识点	只作建议，不回写

- 原则：若某类缺陷无法可靠映射到知识点，则不回写，宁缺毋滥。
 - 回写的证据权重只有正式测验的一半，且必须教师采纳之后才生效。

演示四 · 把大模型接上去，看结论变不变

改一行配置，重启 —— 右上角从「离线降级」变成模型名

对比项	离线表达式	接上大模型后
班级诊断的结论（Top3、根因、名单）	—	逐字节相同
缺口计算与挡路度排序	—	逐字节相同
置信度与证据条数	—	完全相同
措辞	模板化、略生硬	自然、有铺垫

- 这条结论已经写成自动化测试，每次提交都会跑一遍。
- **含义：**今天用这个模型，明年出了更强的换掉即可——系统能力自动提升，此前积累的一切不受影响。

现场如果没有网络或 Key，用本机假底座演示同一件事：`python3 aiedu.py mock-llm`



四、它如何随时间变强

一套系统上线即定型，三年后必被淘汰。设计目标是：用得越久越有价值

三类会持续增厚的资产

资产	增长方式	价值
知识图谱	一门课建好永久复用，每年新增一到两门	增长最慢，但一旦建成极难被替代
错误模式库	每运行一届，在每个知识点上沉淀真实错误样本与归因	三类里最有价值，也最容易被忽略
学生状态历史	每届学生的完整成长轨迹被结构化保留	反过来改进培养方案本身

- 一位从教二十年的教师，最不可替代的能力不是讲得比别人清楚，而是**他知道学生会在哪里犯错、错的背后通常是哪个概念没通。**
 - 这份经验从未被记录，教师退休即消失，新教师只能从头再积累一遍。
 - 三届之后，这个库能回答一个新教师问不出、老教师答得出的问题：**这个知识点，学生通常错在哪？**

可替换与可积累的分界

任何可积累的东西，都不得依赖任何可替换的东西的内部实现。

部件	归属	设计要求
大模型	可替换	接口标准化，随时可整体更换
检索与生成策略	可替换	允许迭代重写
知识图谱	可积累	格式长期稳定，只增不毁
错误模式库	可积累	持续沉淀，独立于模型版本
学生状态历史	可积累	结构化留存，支持长周期分析

可审计性：状态不是模型说的，是事件算出来的

- 学习事件流**只追加**：数据库层面禁止修改与删除，违反即报错。
- 任何状态——包括掌握度、连续天数、成就——都可以从事件流完整重算。
 - 当前演示数据：60 名学生、4934 条事件，重算校验 **60/60 一致**。
- 掌握度必须挂在具体事件上，否则数据库拒绝写入。
- **任何人都可以拿走事件流自己重算一遍。**
 - 这是系统可被第三方核查的基础，也是我们对 " 数据能不能采信 " 这个问题的正面回答。

参照：某国外同类项目因拒绝独立验证而被质疑击穿。可核查性从第一天就要设计进去，事后补不上。

激励：只对「坚持」给正反馈

应当奖励

- 连续天数、中断后回归
- 攻克一个根因知识点（破关）
- 项目里程碑、真机跑通
- 失败后重来并通过

明令禁止奖励

- 正确率
- 做题数量
- 停留时长
- 排名（避免挫伤后进者）

- 原则：让 " 坚持 " 上瘾，不让 " 简单 " 上瘾。
 - 这条同样不靠自觉——代码里是白名单，传入正确率类激励直接报错。
- 若系统以 " 提高当场答对率 " 为目标，会训练出让学生越学越弱的系统。评测指标的选择本身就是架构决策。



五、现在做到了什么

不是 PPT 方案，是可以现场跑起来的系统

已完成的系统（可现场核对）

项目	数量	说明
知识点 / 依赖边	183 / 224	试点课程《机器学习原理与应用》，导入强制环检测
能力模块	8	M1-M8，每个知识点挂 1-3 个
项目 / 任务 / 任务 - 知识点映射	2 / 35 / 115	AGV 与机器视觉，映射由导师标注
虚拟班级 / 学习事件	60 人 / 4934 条	全部经追踪器写入，可完整重算
错误模式 / 原始实例	8 / 60	从第一天开始积累
项目信号	1388 条	由适配器归一化为五类标准信号
自动化测试	83 个用例	含架构铁律的静态检查，全部通过

开源地址：github.com/codesoldier99/AI_EDU

克隆后两条命令即可跑起来，无需数据库服务、无需网络、无需 API Key。

五类标准信号：接第 5 个和第 10 个项目，成本相同

实验班同期运行 5-10 个异构项目：机器人、机器视觉、大模型应用、数据平台、嵌入式

信号类别	采集内容	可推断的能力维度
代码仓库	提交频次与粒度、变更量、评审记录	工程实现、协作规范性
构建与测试	CI 成功率、测试覆盖、缺陷修复周期	工程质量意识、调试能力
运行时	任务成功率、关键指标、异常重试、调参轨迹	系统调优、问题定位
文档与交付	设计文档、技术报告、答辩材料完整性	技术表达、系统性思维
协作	看板流转、评审互动、接口沟通	团队协作、项目管理

- 新项目接入 = 写一个适配器，**核心系统一行不改**（这一条也写成了自动化测试）。

系统研发本身就是实验班的实战项目

原则：接口清晰、可独立验收的交给学生；决定骨架的由导师把关

模块	归属	难度	覆盖能力
知识点标注与图谱构建	学生	★	知识梳理、数据工程
项目适配器开发	学生分组并行	★★	接口设计、数据处理
画像看板前后端	学生	★★	Web 全栈
静态分析工具链集成	学生	★★	工程规范
RAG 检索优化与召回评测	学生（进阶）	★★★	检索、评估方法
追问策略引擎	导师带核心学生	★★★★	算法设计
状态模型与层间接口	导师	★★★★★	做错返工代价极高
任务 - 知识点映射标注	导师	★★★	学分认定依据，须可靠

须避免一个常见误区：不能把学生当免费劳动力去堆功能。每个模块都要有明确的接口契约与验收标准。



六、恳请各位老师拍板

以下参数决定系统形态。代码已全部做成配置，但初值需要教学经验给定

八件需要一线教学经验的事

#	问题	当前初值
1	知识点拆到多细？一门课 300 还是 500 个？	183 （偏粗）
2	先做哪门课、先接哪 1-2 个项目？	机器学习； AGV + 机器视觉
3	掌握度低于多少判定「未掌握」、进入缺口？	0.75
4	追问几次之后降级？ 各级给多少提示？	3 次，三级梯度
5	五类项目信号如何加权映射到 M1-M8 ？	待标定
6	诊断报告里最想第一时间看到哪几件事？	见演示一（可增删）
7	哪些代码缺陷可以可靠回写知识点？	目前只认 5 条
8	一个叶子任务挂几个知识点合适？	3-6 个

第 6 条最关键：报告要让教师每天愿意打开，就必须直接回答他真正关心的问题。多余的字段我们删掉。

还有两个问题，只有各位能回答

- **指导项目时，你实际上是凭哪些迹象判断一个学生真的懂了？**
 - 实践能力的评估最难客观化。把这些迹象说清楚，才能转化为系统的信号。
- **学生反复卡住时，系统应坚持追问还是直接讲解？**
 - 取舍方向已经定死了：降级是为了防止挫败感摧毁动机，不是为了让学生轻松。问题不是要不要降级，而是几次之后降、每级给多少。

风险与对策

风险	影响	对策
学生端使用率低（国外同类产品仅 15% 学生经常使用）	高	教师侧先行；参与度观测提前到第一阶段；嵌入既有流程；只奖励坚持
任务 - 知识点映射工作量大	高	首批只做 2 个项目验证粒度；大模型给候选、教师确认
拉取式导致知识零散	中	保留知识覆盖图；期末按图谱体系性补漏；出口统考不变
冷启动期诊断不准	中	显式置信度；前三周标注「数据不足」
教师抵触	高	建议非指令、一键否决、 不生成教师评价数据
大模型换代返工	中	封装隔离；可积累数据不依赖模型格式（今天已演示）

下一步

▪ 近期（本学期内）

- 试点课程知识点由当前规模细化到 300–500 个，由课程组分工标注。
- 接入第一门课的真实作业与测验数据，教师端进入日常使用。
- 首批 2 个项目的任务 - 知识点映射由导师完成确认。

▪ 中期

- 接入校内 Git 与 CI，项目信号从真实数据采集，不再依赖演示数据。
- 错误模式库开始由教师逐条确认，这是最需要各位投入、也最有长期价值的一件事。

▪ 战略（最容易做出国际级贡献的位置）

- 全球仅极少数教学系统有随机对照试验级证据，中文工科场景近乎空白。
- 从现在起按可发表标准采集：实验班 vs 对照组、**延迟后测**作主指标、研究方案预注册。

注意：主指标必须是延迟后测与迁移任务，不能是当场正确率——否则会训练出让学生越学越弱的系统。

把大模型放在它该在的位置上

状态与表达分离，是这套方案唯一真正重要的技术判断。
它决定了三年之后，我们手上留下的是一堆过时的提示词，
还是一份越用越厚的学院资产。

恳请各位老师批评指正。